多元统计 11

罗震林

1 Question 11.1

1.1 (a)

由题易知,线 f(x,y)=ax+by+c=0 的法向量为 $\overrightarrow{n}=(a,b)$. 设点 (h,k) 为 A,作 $AB\perp f(x,y)$ 交 f(x,y) 于 $B(x_0,y_0)$,则有 $ax_0+by_0+c=0$.

因为 \overrightarrow{n} 和 \overrightarrow{BA} 都垂直于 f(x,y), 所以 \overrightarrow{n} 和 \overrightarrow{BA} 共线, 从而有

$$\overrightarrow{n} \cdot \overrightarrow{BA} = \pm |\overrightarrow{n}||\overrightarrow{BA}|$$

$$= (a,b) \cdot (h - x_0, k - y_0)$$

$$= a(h - x_0) + b(k - y_0)$$

$$= ah + bk - (ax_0 + by_0)$$

$$= ah + bk + c$$

因此,

$$\begin{split} |\overrightarrow{BA}| &= \frac{|\overrightarrow{n} \cdot \overrightarrow{BA}|}{|\overrightarrow{n}|} \\ &= \frac{|ah + bk + c|}{\sqrt{a^2 + b^2}} \end{split}$$

所以,点 (h,k) 到线 f(x,y) 的垂直距离为 $|ah+bk+c|/\sqrt{a^2+b^2}$

1.2 (b)

不妨将问题转化为

minimize
$$\frac{1}{2}||\mathbf{x} - \mathbf{x}_k||^2$$

subject to $\mu(\mathbf{x}) = \beta_0 + \mathbf{x}^T \boldsymbol{\beta} = 0$

使用拉格朗日乘子法,则

$$L(\mathbf{x}, \lambda) = \frac{1}{2} (\mathbf{x}^T \mathbf{x} - 2\mathbf{x}^T \mathbf{x}_k + \mathbf{x}_k^T \mathbf{x}_k) + \lambda (\beta_0 + \mathbf{x}^T \boldsymbol{\beta})$$

对 x 求偏导且令其等于 0, 有

$$\frac{\partial L}{\partial \mathbf{x}} = \mathbf{x} - \mathbf{x}_k + \lambda \boldsymbol{\beta} = 0$$

从而满足条件的解 x^* ,有

$$\mathbf{x}^* = \mathbf{x}_k - \lambda \boldsymbol{\beta}$$

带入约束条件中,有,

$$\beta_0 + \mathbf{x}^{*T} \boldsymbol{\beta} = \beta_0 + \mathbf{x}_k^T \boldsymbol{\beta} - \lambda \boldsymbol{\beta}^T \boldsymbol{\beta} = 0$$
$$\lambda = \frac{\beta_0 + \mathbf{x}_k^T \boldsymbol{\beta}}{\boldsymbol{\beta}^T \boldsymbol{\beta}}$$

从而 \mathbf{x}_k 到超平面的最短垂直距离为

$$||\mathbf{x} - \mathbf{x}_k|| = ||\lambda \boldsymbol{\beta}|| = |\lambda|||\boldsymbol{\beta}||$$

$$= \frac{|\mu(\mathbf{x})|}{||\boldsymbol{\beta}||^2}||\boldsymbol{\beta}||$$

$$= \frac{|\mu(\mathbf{x})|}{||\boldsymbol{\beta}||}$$

2 Question 11.6

设
$$\mathbf{x} = (x_1, y_1)^T, \mathbf{y} = (y_1, y_2)^T,$$
则

$$K(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle^2 = (x_1 y_1 + x_2 y_2)^2$$

= $x_1^2 y_1^2 + x_2^2 y_2^2 + 2x_1 x_2 y_1 y_2$

所以 $\Phi_1(\mathbf{x}) = (x_1^2, x_2^2, \sqrt{2}x_1x_2)^T$ 和 $\Phi_2(\mathbf{x}) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)^T$ 都满足

$$K(\mathbf{x}, \mathbf{y}) = \langle \mathbf{\Phi}_1(\mathbf{x}), \mathbf{\Phi}_1(\mathbf{y}) \rangle = \langle \mathbf{\Phi}_2(\mathbf{x}), \mathbf{\Phi}_2(\mathbf{y}) \rangle$$

且 $\Phi_1(\mathbf{x})$ 和 $\Phi_1(\mathbf{x})$ 都是 \mathcal{R}^2 到 \mathcal{R}^3 的映射

3 Question 11.11

将(11.41)写成矩阵形式有

$$\begin{split} F_D(\theta \boldsymbol{\alpha}) &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^T \mathbf{x_j}) \\ &= \mathbf{1}^T \boldsymbol{\alpha} - \frac{1}{2} \boldsymbol{\alpha}^T Q \boldsymbol{\alpha} \end{split}$$

其中,Q 为对称矩阵,且第 (i,j) 个元素为 $Q_{ij}=y_iy_j\mathbf{x}_i^T\mathbf{x}_j$ 所以,将不等式左右两边依次改写成矩阵形式有

$$F_D(\theta \boldsymbol{\alpha} + (1 - \theta)\boldsymbol{\beta}) = \mathbf{1}^T (\theta \boldsymbol{\alpha} + (1 - \theta)\boldsymbol{\beta}) - \frac{1}{2} (\theta \boldsymbol{\alpha} + (1 - \theta)\boldsymbol{\beta})^T Q (\theta \boldsymbol{\alpha} + (1 - \theta)\boldsymbol{\beta})$$

$$\theta F_D(\boldsymbol{\alpha}) = \theta [\mathbf{1}^T \boldsymbol{\alpha} - \frac{1}{2} \boldsymbol{\alpha}^T Q \boldsymbol{\alpha}]$$

$$(1 - \theta) F_D(\boldsymbol{\beta}) = (1 - \theta) [\mathbf{1}^T \boldsymbol{\beta} - \frac{1}{2} \boldsymbol{\beta}^T Q \boldsymbol{\beta}]$$

从而有

$$F_{D}(\theta\boldsymbol{\alpha} + (1-\theta)\boldsymbol{\beta}) - [\theta F_{D}(\boldsymbol{\alpha}) + (1-\theta)F_{D}(\boldsymbol{\beta})]$$

$$= \frac{1}{2} [\theta \boldsymbol{\alpha}^{T} Q \boldsymbol{\alpha} + (1-\theta)\boldsymbol{\beta}^{T} Q \boldsymbol{\beta} - \theta^{2} \boldsymbol{\alpha}^{T} Q \boldsymbol{\alpha} - (1-\theta)^{2} \boldsymbol{\beta}^{T} Q \boldsymbol{\beta} - \theta(1-\theta)\boldsymbol{\beta}^{T} Q \boldsymbol{\alpha} - \theta(1-\theta)\boldsymbol{\alpha}^{T} Q \boldsymbol{\beta}]$$

$$= \theta (1-\theta) \frac{1}{2} [\boldsymbol{\alpha}^{T} Q \boldsymbol{\alpha} + \boldsymbol{\beta}^{T} Q \boldsymbol{\beta} - \boldsymbol{\beta}^{T} Q \boldsymbol{\alpha} - \boldsymbol{\alpha}^{T} Q \boldsymbol{\beta}]$$

$$= \theta (1-\theta) \frac{1}{2} (\boldsymbol{\alpha} - \boldsymbol{\beta})^{T} Q (\boldsymbol{\alpha} - \boldsymbol{\beta})$$

又因为 $0 < \theta < 1$, 且

$$Q = \begin{pmatrix} y_1 \mathbf{x}_1^T \\ \vdots \\ y_n \mathbf{x}_n^T \end{pmatrix} \begin{pmatrix} y_1 \mathbf{x}_1 & \cdots & y_n \mathbf{x}_n \end{pmatrix} = C'C$$

其中 C 为 n 阶实矩阵, 所以 Q 是半正定的, 从而可以得到

$$F_D(\theta \boldsymbol{\alpha} + (1 - \theta)\boldsymbol{\beta}) - [\theta F_D(\boldsymbol{\alpha}) + (1 - \theta)F_D(\boldsymbol{\beta})] \ge 0$$

证毕

4 Question 11.12

选取的 C 和 $\gamma = \frac{1}{\sigma^2}$ 如下

$$C = 10, 80, 100, 200, 500, 1000$$

$$\gamma = 0.00001, 0.0001, 0.002, 0.01, 0.04$$

4.1 数据预处理

同书上的处理方式一样,对 0 值赋值 0.001,然后再取对数;同时设置好 C 和 γ 的值

4.2 SVM 交叉验证

```
set.seed(1234)
N <- nrow(wdbc)</pre>
index <- sample(1:N, N, replace = F)</pre>
CV <- matrix(0, nrow = 6, ncol = 5) # 初始化, 储存错误率
rownames(CV) <- c(10,80,100,200,500,1000)
colnames(CV) <- c(0.00001,0.0001,0.001,0.01,0.04)</pre>
CV <- as.data.frame(CV)
for (k in 1:6) {
 for (t in 1:5) {
   for (i in 1:10) {
    id <- (57*(i-1)+1):(57*i) # 分割数据集
   valid_index <- index[id]</pre>
   train_index <- index[-id]</pre>
   train <- wdbc[train_index,]</pre>
   valid <- wdbc[valid_index,]</pre>
    valid <- na.omit(valid) # 忽略NA
    out <- svm(V2~., data = train, kernel="radial",
        cost = C[k], gamma = gam[t])
   pred <- predict(out, valid)</pre>
   A <- table(valid$V2, pred)
    CV[k,t] \leftarrow CV[k,t] + (sum(A) - sum(diag(A))) / nrow(valid)
  CV[k,t] \leftarrow CV[k,t]/10
 }
```

表 1: 交叉验证结果

C γ	0.00001	0.0001	0.002	0.01	0.04
10	0.15648496	0.04746241	0.02108396	0.02462406	0.02459273
80	0.05272556	0.02283835	0.02462406	0.02108396	0.02634712
100	0.04746241	0.01932957	0.02459273	0.01929825	0.02634712
200	0.02991855	0.01932957	0.02459273	0.03164160	0.02634712
500	0.02459273	0.01757519	0.02634712	0.02988722	0.02634712
1000	0.01932957	0.02108396	0.02634712	0.02988722	0.02634712

通过表1,很容易看到,当 (C,γ) = (500,0.0001) 时,误判率最小,为 0.01757519. 进一步,我们使用 LDA 和分类树进行交叉验证,比较三种方法的优劣

4.3 LDA 交叉验证

```
err_lda <-0
for (i in 1:10) {
   id <- (57*(i-1)+1):(57*i)
   valid_index <- index[id]
   train_index <- index[-id]

   train <- wdbc[train_index,]
   valid <- wdbc[valid_index,]
   valid <- na.omit(valid)
   out <- lda(V2-., data = train)

   pred <- predict(out, valid)

   A <- table(valid$V2, pred$class)
   err_lda<- err_lda +sum(A)-sum(diag(A)))
}
err_lda<- err_lda/569</pre>
```

经计算,使用 LDA 进行交叉验证得到误判率为 0.04570802

4.4 分类树交叉验证

```
err_t <-0
for (i in 1:10) {
   id <- (57*(i-1)*1):(57*i)
   valid_index <- index[id]
   train_index <- index[-id]

   train <- wdbc[train_index,]
   valid <- wdbc[valid_index,]
   valid <- na.omit(valid) # delete NA

   out <- rpart(V2-., method = "class",data = train)

   pred <- predict(out, valid, type="class")

A <- table(valid$V2, pred)
   err_t<- err_t +(sum(A)-sum(diag(A)))/nrow(valid)
}
err_t <- err_t/10</pre>
```

分类树进行交叉验证得到的误判率为 0.08436717

4.5 总结

通过自行划分数据,使上述三种方法进行交叉验证所使用的训练集和测试集都相同,最后计算得到的结果是: SVM 的误判率最低,效果最好,其次是 LDA,最差的是分类树,且差异较明显; 但是 SVM 要得到较好的结果,需要调参,会运行更长的时间